Lineare und Logistische Regression

Dr. Lucia Kleint HS 2020



Übungsblatt LE2

Lösungen

Lösung 1.

- (a) 60.65% ($\lambda = 1/6000$ und $\exp(-\lambda * 3000) = 0.6065$)
- (b) $47.86\% \left(\exp(-1/6000 * 1000) \exp(-1/6000 * 6000) = 0.4786 \right)$

Lösung 2.

- (a) 28.65% ($\lambda = 1/8$ und $\exp(-\lambda \cdot 10) = 0.2865$)
- (b) 63.21% $(1 \exp(-1/8 * 8) = 0.6321)$

Lösung 3.

- (a) $\lambda = 0.1 \ (\lambda = -\ln(1 .2592)/3.)$
- (b) 10 Jahre (= $1/\lambda$)
- (c) 6.93 Jahre (= $-\ln(0.5) \cdot 10$)

Lösung 4.

- (a) 0
- (b) In python: import scipy.stats scipy.stats.norm(125, 5).cdf(130)-scipy.stats.norm(125, 5).cdf(120) = 0.68
- (c) scipy.stats.norm(125, 5).cdf(110) = 0.0013
- (d) scipy.stats.norm.ppf(0.05, loc=125, scale=5) = 116.8 g

Lösung 5.

scipy.stats.norm.ppf(0.9, loc=80, scale=10) = 92.8 kg

Lösung 6.

- (a) $\mu = 32 \ (=(24+34+32+36+38+32+28)/7) \ \text{und } \sigma = 4.761.$
- (b) Konfidenzintervall $[\mu t\frac{\sigma}{\sqrt{n}}, \mu + t\frac{\sigma}{\sqrt{n}}]$. Man hat 7 Datenpunkte, d.h. 6 Freiheitsgrade. t schaut man in einer Tabelle nach, z.B. ttable.org für one-tail 0.025 (=1 α /2, wobei α = 0.95) bzw. two-tails 0.05: $t_{0.975,6} = 2.447$. $\rightarrow [32 2.447 \cdot 4.761/\sqrt{7}, 32 + 2.447 \cdot 4.761/\sqrt{7}] = [27.597; 36.403]$ (t-Verteilung!)
- (c) Analog zu vorheriger Lösung mit $t_{0.95.6} = 1.943$. [28.504; 35.496] (t-Verteilung!)

Lösung 7.

Es ist $\bar{x} = 50.14$ und $\sigma = 0.3962$

- (a) $[50.14 1.895 * 0.396232/\sqrt{8}, 50.14 1.895 * 0.396232/\sqrt{8}] = [49.875; 50.405]$ (t-Verteilung!)
- (b) $[50.14 5.408 * 0.396232/\sqrt{8}, 50.14 5.408 * 0.396232/\sqrt{8}] = [49.382; 50.898]$ (t-Verteilung!)

Lösung 8.

Eine Irrtumswahrscheinlichkeit von 4.55% heisst, dass man das z sucht, welches 1-.0455/2=0.97725 (zweiseitiger Test), also den Flächeninhalt unter der Normalverteilung von 97.7% ergibt. In einer Tabelle der Standardnormalverteilung findet man $\Phi_{0;1}(2)=0.97725$ oder via Python from scipy.stats import norm und norm.ppf(.97725), was 2 gibt.

Das Konfidenzintervall ist $[\bar{x} - z \frac{\sigma}{\sqrt{n}}, \bar{x} + z \frac{\sigma}{\sqrt{n}}] = [600000 - 2.90000 / \sqrt{225}, 600000 + 2.90000 / \sqrt{225}] = [588000; 612000]$ (Standardnormalverteilung!)

Lösung 9.

- (a) $lohn = 2.83 * m_i + 12.67 (m_i = 1 \text{ für Mann und 0 sonst})$
- (b) $R^2 = 0.41$, also nicht ideal, aber nicht unkorreliert.
- (c) Man benützt den Wert der t-Verteilung für $\alpha/2=0.025$ (für ein 95% Konfidenzintervall). Die Anzahl der Freiheitsgrade ist n-2=12-2=10. $t_{(1-\alpha/2)}(n-2)=2.228$ (aus der t Tabelle). Die Standardabweichung für die Steigung ist 1.078 (s. Fahrmeir, S.444 oder z.B. via OLS summary() in Python). Konfidenzintervall: $2.83 \pm 2.228 \cdot 1.078$, d.h. [0.43, 5.23].
- (d) Der Zweistichproben-t-Test verlangt identische Varianzen. Wir berechnen die Standardabweichungen des Lohns von Schülerinnen und Schülern und erhalten 1.37 und 1.98. Da sie nicht identisch sind, ist der Zweistichproben-t-Test nicht verwendbar.